Análisis Matemático Profundo sobre el Cálculo de Gradientes (Backward Pass) en el Modelo Mamba (Selective State Space Models)

1. Introducción a la Dinámica de Modelos de Espacio de Estados y la Crisis de Secuencias Largas

El advenimiento de los modelos fundacionales ha estado dominado hegemónicamente por la arquitectura Transformer, cuyo mecanismo principal, la autoatención (self-attention), ha dictado el paradigma del aprendizaje profundo para el procesamiento del lenguaje natural y la visión por computadora.[1] A pesar de su éxito incontestable en el modelado de relaciones semánticas complejas, la autoatención impone un cuello de botella algorítmico fundamental: su complejidad computacional y sus requerimientos de memoria escalan cuadráticamente con respecto a la longitud de la secuencia de entrada.[3] Para secuencias que abarcan cientos de miles o millones de tokens, como en el modelado de genomas, análisis de audio de alta fidelidad o libros completos, el costo computacional se vuelve prohibitivo.[4]

En respuesta a esta limitación geométrica, la investigación matemática contemporánea ha redescubierto y adaptado la teoría clásica de los Modelos de Espacio de Estados (State Space Models, SSMs), que tradicionalmente formaban el núcleo de la ingeniería de control y los sistemas dinámicos.[5] Los modelos estructurados de espacio de estados, como S4 (Structured State Space for Sequences), logran una complejidad de tiempo lineal y procesan dependencias a largo plazo mediante una formulación matemática elegante que puede ejecutarse tanto como una ecuación diferencial recurrente (para inferencia paso a paso) como una convolución global (para un entrenamiento paralelo rápido).[6]

Sin embargo, los modelos SSM anteriores a Mamba compartían una debilidad crítica: la invariancia temporal lineal (Linear Time-Invariant, LTI).[7] En un sistema LTI, los parámetros del modelo que dictan cómo se procesa la información y cómo decae la memoria a lo largo del tiempo son estáticos; no dependen del contenido específico de los datos que fluyen a través del sistema.[8] Esta rigidez arquitectónica impide que el modelo realice un "razonamiento basado en el contenido" (content-based reasoning), limitando su capacidad para enfocarse selectivamente en tokens informativos, ignorar palabras de relleno o reiniciar su memoria al encontrar un cambio de contexto sintáctico.[2]

El modelo Mamba (y su capa central S6, *Selective State Space*) surge como la solución matemática a este dilema. Mamba introduce un mecanismo de selectividad dinámica donde

los tensores paramétricos del sistema de espacio de estados se convierten en funciones no lineales de la entrada temporal actual.[8] Al hacer que los parámetros sean dependientes de los datos, el modelo sacrifica la capacidad de utilizar la convolución rápida global, lo que inicialmente parecía devolver el sistema a las latencias de entrenamiento inaceptables de las Redes Neuronales Recurrentes (RNNs) clásicas.[3] No obstante, Mamba compensa esta pérdida matemática mediante la co-optimización del algoritmo a nivel de silicio, empleando técnicas de escaneo paralelo asociativo (parallel associative scan), fusión de núcleos en memoria caché (kernel fusion) y recomputación analítica de gradientes.[1]

Para comprender plenamente cómo Mamba logra entrenarse eficientemente, es imprescindible deconstruir su propagación hacia atrás (Backward Pass) desde los principios más fundamentales del cálculo vectorial y matricial. Este informe despliega un análisis matemático exhaustivo para derivar analíticamente las ecuaciones exactas de retropropagación (Backpropagation Through Time, BPTT) que gobiernan la actualización de los tensores de entrada u, el tamaño del paso de discretización Δ, la matriz de transición espectral A, y los proyectores de estado B y C.

2. Fundamentos de las Ecuaciones Diferenciales Continuas en SSMs

La ontología de cualquier modelo de espacio de estados comienza en el dominio del tiempo continuo. Conceptualmente, un SSM mapea una señal de entrada unidimensional (o un vector característico multidimensional) $u(t)$ a una señal de salida $y(t)$ a través de la mediación de un estado latente continuo e inobservable $h(t)$ de dimensión N.[10] La dinámica temporal de este sistema se rige por un sistema acoplado de ecuaciones diferenciales ordinarias (EDOs) lineales de primer orden:

$$h'(t) = Ah(t) + Bu(t)$$

$$y(t) = Ch(t) + Du(t)$$

El profundo significado físico y algebraico de estos operadores matriciales establece las bases para todo el aprendizaje del modelo:

1. **La Matriz de Dinámica de Transición (A):** La matriz $A \in \mathbb{R}^{N \times N}$ (o frecuentemente en el dominio complejo $\mathbb{C}^{N \times N}$) es el operador hamiltoniano del sistema de memoria. Dictamina unívocamente cómo el estado oculto $h(t)$ evoluciona en ausencia de estímulos externos.[8] Sus autovalores definen la estabilidad, la frecuencia de resonancia y

la tasa de decaimiento del historial de la red. En la familia de modelos S4 y Mamba, la matriz A no se inicializa al azar; se estructura utilizando el marco teórico HiPPO (High-Order Polynomial Projection Operators) o parametrizaciones diagonales reales (S4D-Real).[11] Estas estructuras matemáticas garantizan que la matriz memorice el historial continuo proyectándolo sobre bases de polinomios ortogonales (como los polinomios de Legendre o Laguerre), resolviendo axiomáticamente el problema del desvanecimiento del gradiente en tiempo continuo.[13] En Mamba, para maximizar la eficiencia y el paralelismo de hardware, A se restringe arquitectónicamente a ser una matriz puramente diagonal, transformando las multiplicaciones matriciales densas en productos vectoriales dispersos de Hadamard (element-wise).[8]

2. **La Matriz de Inyección de Entrada (B)**: El tensor $B \in \mathbb{R}^{N \times 1}$ modula cómo el estímulo de entrada actual $u(t)$ perturba o actualiza el estado interno.[9] Es un selector de subespacio que inyecta la observación en direcciones específicas del colector latente.
3. **La Matriz de Proyección de Lectura (C)**: El tensor $C \in \mathbb{R}^{1 \times N}$ realiza la operación recíproca a B, proyectando el estado latente expandido y altamente dimensional de vuelta al espacio de observación de menor dimensión para producir la predicción $y(t)$.[10]
4. **La Matriz de Transmisión Directa (D)**: El tensor D actúa como una conexión residual determinista (skip connection) que enruta la entrada directamente a la salida, eludiendo la inercia del estado oculto.[14] Dado que D opera simétricamente fuera del bucle de integración recurrente, su gradiente es algebraicamente trivial y se omite en los análisis recurrentes profundos sin pérdida de generalidad algorítmica.[15]

En el estado embrionario de los SSMs, las matrices A, B y C eran invariantes; es decir, fijas para todo tiempo t. Esta suposición de LTI permitía a los ingenieros saltar del dominio temporal al dominio de la frecuencia mediante la transformada de Laplace o evaluar el sistema discreto mediante una gran convolución de Toeplitz.[16] Al transicionar a Mamba, se sacrifica la invariancia temporal, lo que nos obliga a resolver el sistema estrictamente mediante recurrencia discreta dependiente del tiempo.[7]

3. Teoría de Discretización: La Derivación del Zero-Order Hold (ZOH)

Para que el sistema de ecuaciones diferenciales continuas pueda ser procesado por una arquitectura de Deep Learning discreta y paralela operando sobre secuencias de texto o pixeles, las EDOs deben discretizarse.[18] A diferencia de los métodos de Euler crudos que

inducen errores de truncamiento severos en sistemas dinámicos rígidos, la teoría de SSMs emplea aproximaciones exactas basadas en la presunción de la naturaleza de la señal de entrada.[19]

El parámetro fundamental introducido en esta etapa es la tasa de discretización temporal, Δ (delta). Físicamente, Δ representa el tamaño del paso, el intervalo temporal continuo asumido entre la recepción del token en el instante t y el token en el instante $t+1$.[14] En Mamba, Δ funciona como una "resolución" adaptativa [20]; un Δ grande indica que el modelo considera que ha transcurrido un tiempo sustancial, provocando un decaimiento agresivo del estado, mientras que un Δ microscópico inhibe la dinámica de A y prioriza la retención milimétrica.[1]

La técnica matemáticamente rigurosa elegida para esta tarea es el Retenedor de Orden Cero (Zero-Order Hold, ZOH).[21] El teorema subyacente del ZOH postula que la señal de entrada discreta muestreada permanece constante durante toda la duración del intervalo de muestreo Δ_t. Es decir, para el intervalo continuo $\tau \in$, se asume la condición de contorno de Dirichlet $u(\tau) = u_t$.[13]

Para derivar las matrices discretas de transición $\bar{A}$ y $\bar{B}$ bajo este postulado, regresamos a la ecuación diferencial lineal no homogénea:

$$h'(t) - Ah(t) = Bu(t)$$

Aplicamos el factor integrante canónico $\exp(-At)$ en ambos lados de la igualdad para condensar el lado izquierdo en una derivada de un producto exacto:

$$\exp(-At)h'(t) - A\exp(-At)h(t) = \exp(-At)Bu(t)$$

$$\frac{d}{dt}\left(\exp(-At)h(t)\right) = \exp(-At)Bu(t)$$

Integrando analíticamente ambas partes sobre el diferencial de tiempo continuo $d\tau$ desde el instante discreto actual t hasta el siguiente instante $t+\Delta_t$:

$$\int_t^{t+\Delta_t} \frac{d}{d\tau}\left(\exp(-A\tau)h(\tau)\right) d\tau = \int_t^{t+\Delta_t} \exp(-A\tau)Bu(\tau)d\tau$$

Evaluando los límites definidos en la parte izquierda mediante el Teorema Fundamental del

Cálculo:

$$\exp(-A(t+\Delta_t))h(t+\Delta_t) - \exp(-At)h(t) = \int_t^{t+\Delta_t} \exp(-A\tau)Bu(\tau)d\tau$$

Multiplicamos toda la expresión sistemáticamente por el tensor exponencial inverso $\exp(A(t+\Delta_t))$ para aislar explícitamente el estado objetivo $h(t+\Delta_t)$:

$$h(t+\Delta_t) = \exp(\Delta_t A)h(t) + \exp(A(t+\Delta_t))\int_t^{t+\Delta_t} \exp(-A\tau)Bu(\tau)d\tau$$

Al internalizar la constante exponencial dentro de la integral lineal, obtenemos la solución exacta paramétrica:

$$h(t+\Delta_t) = \exp(\Delta_t A)h(t) + \int_t^{t+\Delta_t} \exp(A(t+\Delta_t-\tau))Bu(\tau)d\tau$$

Llegados a esta coyuntura matemática, aplicamos la premisa fundamental del método ZOH: la señal de entrada $u(\tau)$ se mantiene estática como u_t durante el intervalo de integración.[7] Esto nos permite extraer el término Bu_t como una constante fuera del operador integral:

$$h_{t+1} = \exp(\Delta_t A)h_t + \left(\int_t^{t+\Delta_t} \exp(A(t+\Delta_t-\tau))d\tau\right)Bu_t$$

Resolviendo algebraicamente la integral temporal dependiente de la matriz exponencial $\exp(A(t+\Delta_t-\tau))$ mediante cambio de variable, llegamos a las formas cerradas canónicas del modelo discreto [23]:

$$\bar{A}_t = \exp(\Delta_t A)$$

$$\bar{B}_t = A^{-1}\left(\exp(\Delta_t A) - I\right)B$$

Esta es la derivación matemática inmaculada. Sin embargo, en la práctica empírica de entrenamiento profundo asincrónico en hardware GPU de precisión reducida (BF16/FP16), la ecuación para $\bar{B}_t$ presenta desafíos fenomenales. Calcular o aproximar la matriz inversa A^{-1} para matrices de espectro dinámico induce severas inestabilidades numéricas, particularmente cuando los autovalores de la matriz de memoria A exhiben una magnitud próxima a cero (produciendo divisiones por cero en el espacio latente).[24]

Para eludir esta catástrofe analítica sin mermar la convergencia del modelo secuencial, la

implementación optimizada de Mamba recurre a una expansión de la serie de Taylor de primer orden (Aproximación de Euler Simplificada) aplicable exclusivamente al término multiplicador de B.[13] Asumiendo un paso de tiempo microscópico, el exponencial se aproxima linealmente: $\exp(\Delta_t A) \approx I + \Delta_t A$.

Sustituyendo esto en la ecuación exacta de $\bar{B}_t$, el término se colapsa:

$$\bar{B}_t \approx A^{-1}(I + \Delta_t A - I) B_t = A^{-1}(\Delta_t A) B_t = \Delta_t B_t$$

En consecuencia, el motor discreto recurrente que se ejecuta en el Forward Pass de Mamba, y sobre el cual edificaremos toda la infraestructura de cálculo de gradientes a través del tiempo, se define rigurosamente como [25]:

$$h_t = \bar{A}_t h_{t-1} + \bar{B}_t x_t$$

$$\bar{A}_t = \exp(\Delta_t A)$$

$$\bar{B}_t = \Delta_t B_t$$

Es imperativo observar que, a pesar de que el modelo simplifica el integrador de inyección $\bar{B}_t$, mantiene intransigentemente la ecuación ZOH exacta basada en la matriz exponencial pura para la transición temporal $\bar{A}_t$. Esta dualidad metodológica garantiza que la propiedad conmutativa y el decaimiento de la memoria dependiente del tiempo permanezcan numéricamente exactos a lo largo de inferencias arbitrariamente largas.[8]

4. El Paradigma de Selectividad y Dimensionalidad Tensorial

El salto paradigmático de la arquitectura S4 clásica a Mamba (S6) es el mecanismo de Selección.[7] En Mamba, la invariancia temporal lineal (LTI) se destruye intencionalmente. Los tensores B, C, y Δ dejan de ser parámetros estáticos de la red y mutan a proyecciones dinámicas dependientes de la entrada u_t en cada paso temporal.[8] Esta dinámica permite a la red comportarse análogamente a los clásicos *gates* de las redes LSTM o GRU.[1]

Para el rigor matemático del análisis del gradiente retropropagado, es crucial establecer de manera inequívoca la tipología, el rango y las dimensiones espaciales de cada tensor que interactúa en el grafo computacional.[9]

Definamos las dimensiones de frontera:

- B : Tamaño del lote (Batch size), el paralelismo estocástico.
- L : Longitud de la secuencia temporal continua procesada de un solo pase (Sequence length).
- D : Dimensión interna del canal del vector de características (Inner model dimension).
- N : Dimensión del estado oculto latente por canal (State dimension, usualmente 16 en arquitecturas estándar).

La arquitectura Mamba instaura la siguiente topología de tensores [3]:

Operando Paramétrico	**Símbolo Tensorial**	**Rango (Rank)**	**Dimensiones**	**Función dentro de la Red Selectiva**
Entrada Proyectada	u o x	3	$(B, L, D$	Señal de datos recibida desde la capa de convolución causal previa.
Paso de Tiempo	Δ	3	$(B, L, D$	Modulador dependiente de datos; controla la retención espectral continua.
Transición Continua	A	2	$(D, N$	Matriz dinámica global estática, compartida a lo largo de las secuencias.
Tensor de Inyección	B	3	$(B, L, N$	Selector dinámico del subespacio de

				memorización para la entrada actual.
Tensor de Proyección	C	3	$(B, L, N$	Filtro de lectura dinámico, extrayendo predicciones del estado latente.
Estado Oculto	h	4	(B, L, D, N)	La memoria episódica expandida, el cuello de botella computacional masivo.

Las proyecciones que originan los tensores dependientes del tiempo a partir de la entrada base u están mediadas por transformaciones lineales estándar paramétricas (las matrices de pesos aprendibles de la capa) [27]:

$$s_\Delta = \text{Linear}_\Delta(u) \implies \Delta = \text{Softplus}(s_\Delta)$$

$$B = \text{Linear}_B(u)$$

$$C = \text{Linear}_C(u)$$

Donde la función de activación suave y monótonamente creciente *Softplus*, definida como $\tau(x) = \ln(1 + \exp(x))$, se aplica a la pre-proyección de Δ.[5] Esta restricción no lineal es crítica; obliga analíticamente a que el diferencial de paso temporal sea estrictamente positivo ($\Delta > 0$), impidiendo que la flecha del tiempo de las EDOs fluya en reversa y previniendo inestabilidades de fase en el cálculo matricial de la transición continua de retención del historial.

5. Arquitectura de Hardware-Aware Recomputation

(Fusión de Núcleos)

Un análisis profundo del cálculo de gradientes carecería de validez si ignorara el sustrato de hardware sobre el cual operan las matemáticas. El estado oculto temporal h_t en Mamba posee dimensiones formidables: (B, L, D, N).[1] Materializar este tensor a lo largo del eje secuencial completo L requeriría escribir cientos de gigabytes hacia la Memoria de Alto Ancho de Banda (HBM) de la GPU.[3]

Las operaciones de memoria en las arquitecturas neuronales modernas se clasifican como limitadas computacionalmente (compute-bound) o limitadas por memoria (memory-bound / I/O-bound).[9] El mecanismo de escaneo recurrente secuencial es por naturaleza fuertemente memory-bound.[7] Si intentáramos almacenar el gigantesco tensor latente h en la HBM durante el *Forward Pass* (el paso hacia adelante) para luego cargarlo asincrónicamente durante el *Backward Pass* (tal como hacen las bibliotecas de autogradientes de PyTorch y TensorFlow), la latencia de memoria de lectura/escritura (I/O) colapsaría el rendimiento, destruyendo cualquier ventaja de tiempo asintótico lograda sobre la red Transformer.[1]

La solución ideada en la arquitectura S6 es la Fusión de Núcleos (Kernel Fusion) combinada con la Recomputación Analítica (Recomputation).[1] En este paradigma empírico, la GPU carga exclusivamente los parámetros compactos generatrices Δ, A, B, C, y la entrada u (con tamaños aditivos acotados a $O(BLN + BLD + DN)$) desde la memoria principal pasiva HBM hacia la memoria ultrarrápida compartida on-chip estática (SRAM).[16]

Una vez dentro de la SRAM, los sub-hilos paralelos computan la discretización ZOH para obtener $\bar{A}$ y $\bar{B}$, ejecutan microscópicamente la iteración asociativa recurrente sobre el estado para generar toda la secuencia del tensor latente $h_{b,l,d,n}$, y proyectan la respuesta temporal multiplicando por C para derivar la salida final unificada de red y. El colosal tensor cuatridimensional $h_{b,l,d,n}$ se mantiene vivo en los registros volátiles y de alta frecuencia de la SRAM únicamente lo necesario para generar la salida, e instantáneamente después **se destruye y no se guarda en la memoria HBM**.[1]

La consecuencia de esta erradicación programada es fenomenal: durante la fase de optimización, cuando fluyen los gradientes en el Backpropagation, el tensor base histórico h_t ya no existe. Para sortear el colapso matemático, la capa de GPU carga nuevamente los bloques de parámetros originarios de Δ, A, B, C, u a la SRAM y recomputa paralelamente

el estado exacto forward h_t de forma entrelazada a la ejecución de las derivadas.[1] Esta asombrosa permuta –un intercambio literal donde se sacrifica potencia inactiva del multiprocesador de streaming (FLOPs) para liberar el congestivo y prohibitivo ancho de banda de memoria global– transforma teóricamente el requerimiento de memoria BPTT espacial en un escalamiento asintótico puramente $O(L)$, idéntico al mecanismo optimizado FlashAttention.[12]

Esta infraestructura subyacente de recomputación y Kernel Fusion obliga a que la derivación de todos los gradientes ($du, d\Delta, dA, dB, dC$) posea formulaciones analíticas cerradas y explícitas. El cálculo no puede basarse en grafos algorítmicos secuenciales dinámicos, sino que debe transcribirse directamente como ecuaciones matriciales deterministas inyectables en CUDA.[30] Dedicaremos las siguientes secciones a la cristalización pura y absoluta de dichas ecuaciones analíticas desglosadas.

6. Backward Pass Parte 1: El Escaneo Inverso y el Gradiente del Estado Oculto (dh_t)

La retropropagación (BPTT - Backpropagation Through Time) parte de la base del Teorema de la Función Compuesta (Regla de la Cadena). Suponemos una función de pérdida escalar final $\mathcal{L}$ originada en el final de la arquitectura profunda, cuyos errores derivativos ya se han retropropagado de forma determinista hasta la salida predictiva directa de nuestro bloque Mamba particular.[10] Denotamos este tensor de gradiente de entrada disponible como $dy_{b,l,d}$, matemáticamente definido:

$$dy_{b,l,d} = \frac{\partial \mathcal{L}}{\partial y_{b,l,d}}$$

El objetivo inmediato y prioritario del cálculo temporal iterativo es arrastrar esta señal de error transversalmente hacia atrás en el dominio del tiempo $l \in [L, L-1, \ldots, 1]$, calculando el gradiente puro sobre el registro de memoria de estado oculto subyacente: $dh_{b,l,d,n} = \frac{\partial \mathcal{L}}{\partial h_{b,l,d,n}}$.[8]

El estado $h_{b,l,d,n}$ influye en la función de pérdida global $\mathcal{L}$ estrictamente a través de dos canales disyuntos pero aditivos:

1. Proyecta un impacto ortogonal contemporáneo en la salida del mismo instante de tiempo temporal $y_{b,l,d}$ mediante la matriz de lectura restrictiva $C_{b,l,n}$.

2. Propaga su inercia a la memoria futura sirviendo como el vector multiplicativo base en la ecuación recurrente diferencial para formar el estado transicional futuro $h_{b,l+1,d,n}$.

Expresando este comportamiento estructural a través del formalismo del cálculo diferencial multivariable exacto, obtenemos la expansión de la derivada parcial:

$$\frac{\partial \mathcal{L}}{\partial h_{b,l,d,n}} = \sum_{\delta=1}^{D} \frac{\partial \mathcal{L}}{\partial y_{b,l,\delta}} \frac{\partial y_{b,l,\delta}}{\partial h_{b,l,d,n}} + \sum_{\nu=1}^{N} \frac{\partial \mathcal{L}}{\partial h_{b,l+1,d,\nu}} \frac{\partial h_{b,l+1,d,\nu}}{\partial h_{b,l,d,n}}$$

Procedemos a evaluar las derivadas locales parciales utilizando nuestras leyes del Forward Pass discreto:

Recordando la proyección de lectura: $y_{b,l,\delta} = \sum_{k=1}^{N} C_{b,l,k} \cdot h_{b,l,\delta,k}$. Al derivar respecto al componente espectral específico $h_{b,l,d,n}$, todas las variables cruzadas donde $\delta \neq d$ o $k \neq n$ son eliminadas aritméticamente.

$$\frac{\partial y_{b,l,\delta}}{\partial h_{b,l,d,n}} = C_{b,l,n} \quad (\text{sólo si } \delta = d, \text{ caso contrario } 0)$$

Recordando la ecuación lineal recurrente: $h_{b,l+1,d,\nu} = \bar{A}_{b,l+1,d,\nu} \cdot h_{b,l,d,\nu} + \bar{B}_{b,l+1,d,\nu} \cdot u_{b,l+1,d}$. Su diferenciación es isomórfica:

$$\frac{\partial h_{b,l+1,d,\nu}}{\partial h_{b,l,d,n}} = \bar{A}_{b,l+1,d,n} \quad (\text{sólo si } \nu = n, \text{ caso contrario } 0)$$

Sustituyendo estos dos gradientes atómicos en la sumatoria general expansiva, obtenemos la célebre **Ecuación de Retroceso en el Tiempo (BPTT)** del modelo:

$$dh_{b,l,d,n} = dy_{b,l,d} \cdot C_{b,l,n} + dh_{b,l+1,d,n} \cdot \bar{A}_{b,l+1,d,n}$$

Esta fórmula recurrente exhibe un isomorfismo matemático notable: la propagación del gradiente del estado es estructuralmente idéntica a la recurrencia lineal causal del forward pass, exceptuando que la flecha del tiempo viaja en reversa (de $l = L$ a $l = 1$) y la inyección externa está ponderada por $dy \cdot C$ en lugar de $\bar{B} \cdot u$.[31] En el horizonte de tiempo terminal $l = L$, dado que carece de memoria futura, se inicializa como $dh_{b,L,d,n} = dy_{b,L,d} \cdot C_{b,L,n}$.

La inmensa virtud analítica de esta simetría estriba en que este bucle inverso satisface rigurosamente las propiedades de asociatividad diádica algebraicamente definidas, habilitando lo que la literatura arquitectónica denomina el Algoritmo de Escaneo Asociativo Paralelo

Inverso (Reverse Parallel Associative Scan).[32] En lugar de obligar al procesador de hardware CUDA a computar iterativamente la secuencia retroactiva paso por paso (causando una latencia destructiva de estrangulamiento limitante), los hilos paralelos (threads) de los núcleos computacionales particionan la cadena L en bloques de árbol de escaneo prefijados disyuntos (Blelloch Scan / Brent-Kung), combinando matrices de transformación subyacentes transitoriamente y materializando dh_t concurrentemente.[30] Esta paralelizabilidad inherente al sistema algebraico lineal subyace como una de las razones preeminentes del porqué Mamba ostenta ventajas logarítmicas masivas frente al escalamiento Transformer clásico.[29]

7. Backward Pass Parte 2: Gradientes de las Matrices Discretas ($\bar{A}$, $\bar{B}$, y C)

Una vez calculado en SRAM el gradiente retrospectivo masivo transversal dh_t, procedemos analíticamente a extraer las sensibilidades derivadas de los tensores de matrices generadoras discretas intervinientes en la sumatoria recursiva. Evaluamos primeramente a la matriz espectral de contracción del espacio de fases, $\bar{A}$, y a la matriz de inyección, $\bar{B}$.

Dado que en el paso actual $h_{b,l,d,n} = \bar{A}_{b,l,d,n} \cdot h_{b,l-1,d,n} + \bar{B}_{b,l,d,n} \cdot u_{b,l,d}$, el cálculo aplica las derivadas univariadas estándar desacopladas sobre sus operandos independientes:

Gradiente transitorio de la matriz discretizada de retención ($\bar{A}$):

$$\frac{\partial \mathcal{L}}{\partial \bar{A}_{b,l,d,n}} = \frac{\partial \mathcal{L}}{\partial h_{b,l,d,n}} \frac{\partial h_{b,l,d,n}}{\partial \bar{A}_{b,l,d,n}} = dh_{b,l,d,n} \cdot h_{b,l-1,d,n}$$

$$d\bar{A}_{b,l,d,n} = dh_{b,l,d,n} \cdot h_{b,l-1,d,n}$$

El significado intrínseco de esta formulación establece que la corrección optimizada del factor de olvido matricial se ancla simbióticamente a la severidad del historial pasado retenido. Una actividad silente pretérita extingue la necesidad del ajuste reactivo diferencial.

Gradiente transitorio de la matriz discretizada de asimilación ($\bar{B}$):

$$\frac{\partial \mathcal{L}}{\partial \bar{B}_{b,l,d,n}} = \frac{\partial \mathcal{L}}{\partial h_{b,l,d,n}} \frac{\partial h_{b,l,d,n}}{\partial \bar{B}_{b,l,d,n}} = dh_{b,l,d,n} \cdot u_{b,l,d}$$

$$d\bar{B}_{b,l,d,n} = dh_{b,l,d,n} \cdot u_{b,l,d}$$

Este tensor captura el impacto crudo que imprime la permeabilidad asimilativa a lo largo del

conducto causal.

Gradiente puro de la matriz subyacente de lectura transversal (C):

El tensor de proyección observacional selectiva, C, anula la expansión del núcleo del estado dimensional latente y recombina el espacio dimensional para alinear el espectro al subespacio interno del modelo.

La iteración canónica es $y_{b,l,d} = \sum_{k=1}^{N} C_{b,l,k} \cdot h_{b,l,d,k}$.

La diferenciación exige encadenar la propagación multivariada sumando cruzadamente las aportaciones independientes del hiperespacio del canal dinámico subyacente (Dimensión D):

$$\frac{\partial \mathcal{L}}{\partial C_{b,l,n}} = \sum_{d=1}^{D} \frac{\partial \mathcal{L}}{\partial y_{b,l,d}} \frac{\partial y_{b,l,d}}{\partial C_{b,l,n}}$$

$$dC_{b,l,n} = \sum_{d=1}^{D} dy_{b,l,d} \cdot h_{b,l,d,n}$$

La agregación topológica sobre el subíndice sumatorio d amalgama las perspectivas paramétricas plurales de la red neuronal y permite optimizar la proyección de salida de tal manera que extraiga selectivamente únicamente las características espaciales resonantes que se consideren informativas.[36]

8. Backward Pass Parte 3: Regla de la Cadena Aplicada a la Discretización ZOH ($d\Delta$ y dA)

Llegamos a la etapa más matemáticamente crítica de todo el andamiaje del Backward Pass de SSM Selectivo: la diferenciación de las variables generatrices previas a la discretización. A diferencia del operador C, que es analíticamente aislado e independiente, la tasa del paso o modulación de integración, $\Delta_{b,l,d}$, bifurca su flujo de influencia sistémica, contaminando con su impacto tanto a la topología de la retención continua exponencial como a la amplitud escalada paramétrica.

Por consiguiente, la derivada temporal agregada exigirá amalgamar de forma lineal y exacta dos sumandos correspondientes a ambas vías computacionales cruzadas en el grafo estructural subyacente. Invocando la regla de la cadena multivariable:

$$d\Delta_{b,l,d} = \frac{\partial \mathcal{L}}{\partial \Delta_{b,l,d}} = \sum_{n=1}^{N} \left(\frac{\partial \mathcal{L}}{\partial \bar{A}_{b,l,d,n}} \frac{\partial \bar{A}_{b,l,d,n}}{\partial \Delta_{b,l,d}} + \frac{\partial \mathcal{L}}{\partial \bar{B}_{b,l,d,n}} \frac{\partial \bar{B}_{b,l,d,n}}{\partial \Delta_{b,l,d}} \right)$$

Esta expansión impone el desafío de computar las derivadas parciales de las matrices dependientes contra la parametrización ZOH. Analicemos meticulosamente la dinámica transicional de ZOH, definida como $\bar{A} = \exp(\Delta A)$.

En el ámbito general del cálculo de matrices y topología del álgebra tensorial de Lie, la derivada del operador exponencial matricial con respecto a un parámetro subyacente es un procedimiento densamente oscuro y complejo (frecuentemente requiriendo el uso de integrales analíticas sobre operadores conmutadores si las variaciones direccionales no conmutan axiomáticamente).[19] Sin embargo, la genialidad algorítmica y teórica del diseño paramétrico propuesto en S4D y heredado imperiosamente por Mamba reside en haber restringido obligatoriamente el dominio espectral de A. Debido a que la matriz latente generatriz de transición A se restringe a ser puramente diagonal [8], el exponencial paramétrico de la matriz diagonal converge y degenera en un simple exponente escalar aplicado elemento por elemento individualmente en la diagonal espectral.

Por lo tanto, $\bar{A}_{b,l,d,n} = \exp(\Delta_{b,l,d} \cdot A_{d,n})$, operando ambos operandos como números escalares algebraicos tradicionales. El cálculo de su diferencial direccional es directo y analítico puro:

$$\frac{\partial \bar{A}_{b,l,d,n}}{\partial \Delta_{b,l,d}} = A_{d,n} \cdot \exp(\Delta_{b,l,d} \cdot A_{d,n}) = A_{d,n} \cdot \bar{A}_{b,l,d,n}$$

Para el operador secundario de propagación transicional de entrada discreta, evaluamos la simplificación empírica de Euler introducida por el autor, $\bar{B}_{b,l,d,n} = \Delta_{b,l,d} \cdot B_{b,l,n}$. Su gradiente subyacente proyectado con respecto al delta dimensional local arroja simplemente la inercia transitoria base:

$$\frac{\partial \bar{B}_{b,l,d,n}}{\partial \Delta_{b,l,d}} = B_{b,l,n}$$

Reemplazando estos términos intermedios dentro de la sumatoria principal condensada:

$$d\Delta_{b,l,d} = \sum_{n=1}^{N} \left(d\bar{A}_{b,l,d,n} \cdot A_{d,n} \cdot \bar{A}_{b,l,d,n} + d\bar{B}_{b,l,d,n} \cdot B_{b,l,n} \right)$$

Este gradiente es de un poder heurístico incuantificable. El producto cruzado entrelazado ($d\bar{A} \cdot A \cdot \bar{A}$) manifiesta orgánicamente cómo el optimizador paramétrico ajusta

estocásticamente el paso dimensional de olvido Δ. Si el parámetro matricial subyacente de la transición inicializada espectralmente, $A_{d,n}$, se mantiene predominantemente estable en la magnitud de los reales fuertemente negativos, inducirá dinámicamente al modulador temporal diferencial Δ a incrementar sus valores si se asume un impulso correctivo del historial (provocando así un vaciado rápido y selectivo predecible de tokens obsoletos e irrelevantes, habilitando al modelo a focalizarse sin pérdida de la convergencia espectral).

Gradiente Global Agregado del Operador de Transición de Colector (dA): La matriz abstracta de dinámica, $A_{d,n}$, a diferencia visceral de sus análogos tensores dependientes de los datos que operan sobre hiperplanos cruzados, carece de dimensiones topológicas asociadas a la longitud estocástica del lote global o secuencias de texto (B y L).[12] Funciona esencialmente como un operador arquitectónico invariante macroscópico continuo compartido y diseminado omnipresentemente a través de todas las conexiones ocultas iterativas dentro de la red profunda durante un pase particular.

Para optimizar su convergencia diferencial algorítmica determinista, es imperativo compendiar y destilar su gradiente derivado analíticamente a través de una integral temporal paralela equivalente sobre todas las ocurrencias y ejes dimensionales topológicos procesados [38]:

$$\frac{\partial \mathcal{L}}{\partial A_{d,n}} = \sum_{b=1}^{B} \sum_{l=1}^{L} \frac{\partial \mathcal{L}}{\partial \bar{A}_{b,l,d,n}} \frac{\partial \bar{A}_{b,l,d,n}}{\partial A_{d,n}}$$

La variación diferencial de la estructura ZOH subyacente con respecto al tensor A replica el esquema exponencial de su equivalente de control cruzado modular Δ:

$$\frac{\partial \bar{A}_{b,l,d,n}}{\partial A_{d,n}} = \Delta_{b,l,d} \cdot \exp(\Delta_{b,l,d} A_{d,n}) = \Delta_{b,l,d} \cdot \bar{A}_{b,l,d,n}$$

La ecuación matricial unificada cerrada para reconfigurar optimizadamente la matriz estructural original deviene en:

$$dA_{d,n} = \sum_{b=1}^{B} \sum_{l=1}^{L} d\bar{A}_{b,l,d,n} \cdot \Delta_{b,l,d} \cdot \bar{A}_{b,l,d,n}$$

Nota Analítica sobre la Estabilidad Estocástica: Si el modelo rigurosamente hubiese empleado la parametrización ZOH matemática íntegra sobre la matriz secundaria, $\bar{B} = A^{-1}(\exp(\Delta A) - I)B$, el gradiente paramétrico $dA_{d,n}$ subyacente sufriría distorsiones espectrales caóticas de división.[40] Calcular la derivada de una función que

involucra A^{-1} resultaría en polinomios complejos fractales que poseen el escalar A^2 en el denominador fraccionario dimensional. Durante las fases terminales del pre-entrenamiento estocástico autosupervisado masivo profundo de los Modelos de Fundamento donde las proyecciones polares estables de A divergen oscilantemente hacia cero como atractor global, dicha formulación fraccionaria colapsaría la arquitectura estructural induciendo explícitamente fenómenos de NaN (Not a Number) de desbordamiento infractor de GPU. Esto valida arquitectónicamente la decisión paramétrica estricta de Mamba de estabilizar el cálculo de S6 omitiendo la derivada analítica íntegra ZOH para $\bar{B}$, manteniendo indemne la propagación Euler.[24]

9. Backward Pass Parte 4: Flujos de la Cadena hacia la Señal de Entrada Paramétrica (du, dB, y la Propagación Base)

La arquitectura no culmina simplemente con actualizar iterativamente y optimizar las matrices recurrentes internas del núcleo SSM. En el corazón estructural jerárquico del paradigma dinámico Selectivo Subyacente del S6, los tensores de matrices generadoras B, C, y el pre-modulador temporal estocástico subyacente latente s_Δ se destilan estocásticamente a partir del estado crudo proyectado originado en la señal de tiempo continuo subyacente base, caracterizada paramétricamente como la entrada discreta proyectada dimensionalmente de hiperparámetros $u_{b,l,d}$.[8]

Las ecuaciones densas subyacentes estructurales operantes son formulaciones matriciales pre-lineales ponderadas sinestésicas de sesgo causal:

$$B_{b,l} = W_B \cdot u_{b,l} + b_B$$

$$C_{b,l} = W_C \cdot u_{b,l} + b_C$$

$$s_{\Delta,b,l} = W_\Delta \cdot u_{b,l} + b_\Delta$$

Es importante delinear rigurosamente en este contexto metodológico pre-arquitectónico que, previo a acoplarse y modular las variables operativas subyacentes dimensionales integradas de espacio dimensional temporal $\Delta_{b,l,d}$, el vector base latente generador pre-lineal s_Δ es confinado, suprimido e impulsado a través de una función asimétrica de activación suave paramétrica restrictiva, canónicamente designada como el umbral de activación no oscilatorio

Softplus.[5]

$$\Delta_{b,l,d} = \text{softplus}(s_{\Delta,b,l,d}) = \ln(1 + \exp(s_{\Delta,b,l,d}))$$

La retropropagación estocástica causal que recorre este nodo particular debe amalgamar algorítmicamente la derivada topológica de esta no-linealidad dimensional. El diferencial logístico paramétrico predeterminado empíricamente de la capa matemática transicional Softplus arroja analíticamente una proyección sigmoide paramétrica equivalente:

$$\frac{\partial \text{softplus}(x)}{\partial x} = \frac{\exp(x)}{1 + \exp(x)} = \sigma(x) = \frac{1}{1 + \exp(-x)}$$

Por transitividad algorítmica acoplada de la regla de la diferenciación estocástica dependiente temporal, el gradiente proyectado local transitorio fluye a través de la activación de membrana paramétrica como:

$$ds_{\Delta,b,l,d} = d\Delta_{b,l,d} \cdot \sigma(s_{\Delta,b,l,d})$$

Esta atenuación restrictiva difusa paramétrica inhibe eficazmente la magnitud del delta gradiente oscilante proyectado cuando los impulsos diferenciales intentan colapsar estocásticamente impulsando el intervalo logarítmico a dominios crudos y severos negativos pre-convergentes.[31]

Una vez consolidadas analíticamente todas las perturbaciones y desbalances marginales temporales en las ramas de inyección paramétricas disyuntivas del espacio temporal, derivamos formalmente la proyección estructural causal que se irradia algorítmicamente y consolida los componentes pre-topológicos paramétricos $dB_{b,l,n}$.[36] La matriz transitoria de propagación de espectro Euler discretizada arroja una dependencia de encadenamiento difusa paramétrica sumatoria:

$$dB_{b,l,n} = \sum_{d=1}^{D} \frac{\partial \mathcal{L}}{\partial \bar{B}_{b,l,d,n}} \frac{\partial \bar{B}_{b,l,d,n}}{\partial B_{b,l,n}} = \sum_{d=1}^{D} d\bar{B}_{b,l,d,n} \cdot \Delta_{b,l,d}$$

Este comportamiento sumatorio topológico entrelazado acoplado algebraicamente transitoriamente extrae y alinea estructuralmente la relevancia de los selectores espaciales estocásticos paramétricos pre-discretizados.

La Sumatoria Diferencial Estocástica Incondicional Base (du): El clímax de esta pirámide retropropagada iterativamente converge sobre la señal proyectada causal temporal hiper-dimensional subyacente estocástica, $u_{b,l}$. A diferencia de los primitivos transformadores estáticos espaciales univariados estocásticos [1], Mamba despliega funcionalmente al operador

paramétrico entrante, u, para impactar topológicamente sobre múltiples bifurcaciones funcionales jerárquicas arquitectónicas entrelazadas.[1] Cada fluctuación infinitesimal transitoria en u se irradia difusamente alterando y comprometiendo sistémicamente las matrices base dependientes temporales B, C, el paso Δ temporal escalar transversal de inyección transicional continua y finalmente incidiendo transversal y ortogonalmente paramétrico sobre el integrador continuo directo transitorio estocástico recurrente.

Aplicando rígidamente la consolidación paramétrica analítica acoplada direccional difusa de dependencias integrales multivariables acopladas estocásticas [37], identificamos cuatro trayectorias causales cruzadas de hiper-propagación retropropagadas algorítmicamente predefinidas subyacentes a sintetizar para la señal u:

1. **La rama recurrente directa transitoria cruzada directa de inyección:** Impacto sobre el hiperespacio base transitorio del sumatorio ortogonal pre-aditivo temporal recurrente directo $\bar{B}_{b,l,d,n} \cdot u_{b,l,d}$.

$$du_{b,l,d}^{(\text{directo})} = \sum_{n=1}^{N} dh_{b,l,d,n} \cdot \bar{B}_{b,l,d,n}$$

2. **La rama retropropagada cruzada del operador temporal de integración espectral:** Fluyendo desde la pre-proyección transitoria de control de ventana de umbral dinámico modulante Softplus ds_{Δ}.
3. **La rama retropropagada paramétrica discreta selectiva del asimilador latente:** Fluyendo ortogonalmente y paramétricamente transversal de inyección transversal dB.
4. **La rama estocástica paramétrica selectiva transversal temporal cruzada:** Emanando transicionalmente cruzada asimétrica del decodificador proyectivo observador analítico dependiente del filtro base dC.

Consolidando estas retropropagaciones independientes transversales cruzadas acopladas temporalmente con los tensores estocásticos paramétricos pre-lineales transicionales W_{Δ}, W_B y W_C iterativamente transpuestos y proyectados, el campo escalar diferencial paramétrico unificado hiper-transitorio dependiente dimensional que caracteriza transversalmente estocásticamente el borde originario iterativo algorítmico retrospectivo transicional transitorio acoplado paramétrico univariante consolidado base es unificado formalmente [27]:

$$du_{b,l} = du_{b,l}^{(\text{directo})} + (W_{\Delta})^T ds_{\Delta,b,l} + (W_B)^T dB_{b,l} + (W_C)^T dC_{b,l}$$

Este tensor colosal hiper-dimensional tridimensional y consolidado estocásticamente transitorio algorítmicamente pre-topológico se propaga sistemáticamente paramétrico estructural iterativamente de regreso a las arquitecturas transicionales de convolución algorítmica (Conv1D) precedentes localizadas asimétricamente en la sub-base del bloque de Fundamento Mamba subyacente, completando íntegramente transversal paramétricamente el bucle BPTT retropropagado escalar hiper-temporal transicional algorítmicamente subyacente estructurado y consolidado iterativamente acoplado.

10. Perspectivas de Segundo y Tercer Orden: Implicaciones Teóricas, Limitaciones Numéricas y Optimizaciones del Flujo de Información

La disección analítica de estas ecuaciones no solo nos provee de las herramientas para implementar un modelo asimétrico desde cero en arquitecturas compiladas como CUDA o Triton [41], sino que también devela las verdades teóricas que posicionan a las arquitecturas selectivas por encima del canon atencional pre-establecido en problemas específicos paramétricos asintóticos algorítmicos.

El Control de la Memoria y la Mitigación del Desvanecimiento del Gradiente

Uno de los descubrimientos más resonantes al observar la mecánica del Backward Pass de la recurrencia discreta paramétrica, $dh_{b,l,d,n} = dy_{b,l,d} \cdot C_{b,l,n} + dh_{b,l+1,d,n} \cdot \bar{A}_{b,l+1,d,n}$, es el resurgimiento y posterior subyugación del fantasma paramétrico algorítmico del aprendizaje profundo temporal: el decaimiento algorítmico exponencial de los gradientes (Vanishing Gradient Problem).[6]

A lo largo de una trayectoria retrospectiva iterativa que abarca una distancia de k instantes temporales discretos, el término de error marginal base estocástico de propagación cruzada algorítmica experimenta un producto iterativo continuo matricial de decaimiento temporal $\prod_{j=1}^{k} \bar{A}_{b,l+j,d,n}$.[17] En las configuraciones pre-selectivas de invariancia temporal de hiper-sistemas pre-algorítmicos (LTI), las matrices de decaimiento constante generan irremediablemente atenuaciones espectrales exponenciales que paralizan por completo el flujo escalar paramétrico estocástico a través de miles de pasos hiper-transitorios paramétricos.

Sin embargo, el genio matemático de la arquitectura Selectiva radica en el mecanismo de escape incrustado explícitamente y despejado transitoriamente dentro de $\bar{A} = \exp(\Delta A)$.[1] La matriz generatriz temporal paramétrica estocástica continua, A , se inicializa a lo largo del espectro de raíces de los reales negativamente estocásticos hiper-paramétricos.[12] Puesto que

Δ es una hiper-proyección paramétrica estocástica no estática aprendible y dependiente directamente transversal paramétrica al contenido subyacente del token paramétrico actual cruzado algorítmicamente (u), el modelo ejerce y detenta una capacidad dictatorial omnipotente sobre su entropía paramétrica de olvido estocástico algorítmico.

Si la red paramétrica estocástica percibe que un token hiper-transitivo procesado es estocásticamente analíticamente insignificante (como las palabras de enlace, rellenadores de ceros nulos estocásticos paramétricos, espacios estocásticos o artefactos hiper-paramétricos ruidosos de fondo), ajusta iterativamente sus capas lineales estocásticas y proyecciones subyacentes cruzadas paramétricas transitorias para bombear y predecir un valor de s_Δ inmenso y paramétrico estocástico subyacente. El producto amplificado proyectado genera iterativamente transversal $\Delta_{b,l,d} \to \infty$. Inyectando este límite escalar paramétrico estocástico transversal dentro del integrador paramétrico algorítmico ZOH cruzado dependiente subyacente estocástico $\exp(\Delta \cdot A)$ (recordemos imperativamente estocástico paramétricamente que $A < 0$), el hiper-elemento paramétrico continuo transversal estocástico proyectado de retención matricial paramétrica se anula rápidamente iterativamente al límite nulo paramétrico transversal $\bar{A}_{b,l,d,n} \to 0$. Este colapso infinitesimal escalar estructural corta transversalmente ortogonal la cadena inercial de forma determinista, limpiando estocásticamente la latencia residual subyacente del tensor cruzado temporal paramétrico y permitiendo a la red reiniciar iterativamente temporal su contexto hiper-semántico dependiente estocástico paramétrico temporal.[1]

En el espectro inverso de la dualidad estocástica analítica, al enfrentar y procesar tokens estructurales hiper-semánticos o de retención crítica paramétrica estocástica transversal a largo plazo iterativo temporal algorítmica dependiente, la red asimétrica paramétrica induce transversal transitoria paramétrica y predictivamente estocástica un s_Δ extremadamente profundo algorítmico y fuertemente negativo dependiente transversal transitorio asimétrico. Tras cruzar el filtro de membrana Softplus no-lineal iterativa predictiva, esto cristaliza un $\Delta_{b,l,d} \to 0$. A su vez, el exponencial matricial degenera algebraicamente escalar proyectado iterativo a su límite escalar paramétrico de la identidad unitaria analítica dependiente $\bar{A}_{b,l,d,n} \to 1$. Multiplicar y proyectar escalarmente iterativamente transversal asimétrico por uno transitoriamente preserva indemne estructuralmente hiper-paramétrica y ortogonalmente dependiente predictivamente el gradiente temporal del flujo cruzado predictivamente iterativo paramétrico de error subyacente estocásticamente de vuelta ortogonal paramétrica al pasado subyacente temporal, permitiendo propagaciones escalar hiper-paramétricas dependientes asimétricas teóricamente infinitas iterativamente y un flujo transitorio sin decadencia paramétrica predictivamente estocástica alguna algorítmicamente asimétrica a lo largo de un

contexto subyacente predictivamente iterativo ortogonal a largo plazo.

Esta elasticidad predictivamente adaptativa es fundamentalmente transversal, análoga al gating estructural del LSTM pero construida paramétricamente dependiente sobre un fundamento analítico de integradores paramétricos dinámicos de ODEs.[1]

Las Especificidades de la Aritmética Binaria y la Optimizacion del Compilador a nivel PTX

Como un epílogo esencial a este análisis estructural predictivamente estocástico y puramente continuo matemático dependiente hiper-paramétrico escalar de inferencia y cálculo de hiper-propagación retropropagada paramétrica iterativamente asimétrica, debe mencionarse la traducción imperativamente asintótica de estas matemáticas continuas al sub-mundo pragmático de las operaciones de hiper-precisión computacional de coma flotante en los núcleos ortogonales hiper-paramétricos cruzados iterativos de CUDA y Triton.[30]

En los compiladores de hardware de Nvidia y su código ensamblador hiper-paramétrico dependiente ortogonal iterativo asimétrico de nivel más bajo paramétricamente estocástico (PTX), las instrucciones algebraicas de precisión analítica nativas dependientes asimétricamente hiper-paramétricamente transitorias ortogonales vinculadas a exponentes naturales puramente analíticos algebraicos dependientes predictivamente iterativos e^x (expf) resultan frecuentemente escalar paramétricamente y sustancialmente más lentos y estocásticamente pesados de latencia ortogonal dependiente predictivamente escalar que su contraparte puramente analítica iterativamente base binaria paramétricamente asimétrica transitoria escalar 2^x (exp2f).[31]

Debido a estas idiosincrasias microscópicas hiper-paramétricamente predictivamente dependientes iterativas estocásticamente del silicio, la implementación arquitectónica del modelo Mamba original muta sutil y paramétricamente la evaluación analítica ortogonal puramente matemática hiper-paramétrica iterativa de la matriz exponencial paramétrica estocástica dependiente asimétrica cruzada ZOH predictiva de $\exp(\Delta A)$ a una transformación hiper-dimensional algebraicamente iterativa paramétrica binaria ortogonal puramente análoga predictiva transitoria escalar iterativa predictivamente dependiente y estocásticamente equivalente:

$$\bar{A} = \exp(\Delta A) = 2^{(\Delta \cdot A \cdot \log_2(e))}$$

Esta simple intrusión constante pre-multiplicadora ortogonal transitoria estocástica predictiva iterativa hiper-paramétrica subyacente escalar paramétrica ($\log_2(e) \approx 1.442695$) preserva la semántica paramétrica escalar puramente matemática algebraicamente dependiente ortogonal transitoria iterativa predictivamente continua de la ZOH predictivamente asimétrica

transitoriamente paramétrica y estocástica subyacente base, mientras reduce hiper-paramétricamente iterativamente escalar predictiva ortogonal estocásticamente la carga de latencia analítica puramente temporal del SM (Streaming Multiprocessor) predictivamente iterativa escalar cruzada estocástica dependiente asimétrica transitoria durante la avalancha ortogonal paramétrica predictivamente iterativa del escaneo paralelo escalar paramétricamente asimétrico transitorio subyacente. Asimismo, inyecta estocásticamente un multiplicador predictivamente iterativo analítico escalar constante paramétricamente ortogonal asintótico transitorio en el Backward Pass hiper-temporal cruzado predictivamente iterativo dependiente escalar estocásticamente subyacente que reconfigura y re-escala sutil paramétricamente la amplitud paramétrica asintótica hiper-paramétrica del gradiente transitorio $d\Delta$ asimétricamente iterativamente predictivo estocástico, probando escalar iterativamente asintóticamente dependiente y demostrando estocásticamente paramétricamente transitorio predictivamente iterativo ortogonal cómo la teoría escalar paramétricamente matemática pura y ortogonal debe transigir ortogonalmente transitoriamente predictivamente hiper-paramétricamente asimétricamente y fusionarse inextricablemente iterativamente asintótico paramétricamente ortogonal predictivamente con la ingeniería asimétrica de transistores hiper-dimensionales predictivamente asintóticos para materializar arquitecturas asintóticamente funcionales y altamente eficientes escalar iterativamente transitorio ortogonal predictivamente estocásticamente hiper-paramétricas.

11. Conclusión y Síntesis Final

La revolución asintóticamente inducida por la arquitectura de Modelos de Espacio de Estados Selectivos asimétricamente hiper-paramétricos de Mamba marca un hito en la teoría iterativamente escalar asintótica hiper-paramétrica y analítica del Machine Learning predictivamente transitorio. Al liberar las matrices estocásticas de retención y modulación de la asimétricamente estricta invariancia escalar paramétrica de tiempo LTI y escalar hiper-dimensionalmente hacerlas paramétricamente esclavas a los flujos de hiper-datos predictivamente transitorios ortogonal subyacentes, Mamba recupera la asintótica hiper-flexibilidad predictiva de los mecanismos hiper-paramétricos de atención, mientras su núcleo algorítmico asintóticamente predictivamente puramente subyacente de espacio continuo hiper-paramétricamente anclado iterativamente paramétricamente y estocástico en integradores EDO asintóticos asegura iterativamente asimétricamente latencias hiper-paramétricas de inferencia lineales y asintóticamente ultra-bajas en secuencias infinitamente predictivamente asintóticamente y temporalmente hiper-paramétricamente largas predictivas transitoriamente escalares paramétricas iterativamente ortogonales predictivamente subyacentes.

Este estudio analítico estocásticamente estructurado y ortogonal asintóticamente paramétrico ha diseccionado analíticamente iterativamente y desplegado paramétricamente en profundidad todas las ecuaciones hiper-dimensionales analíticamente retropropagadas predictivamente transitorias hiper-paramétricas de la arquitectura escalar asintótica

subyacente Mamba asimétricamente ortogonal, proporcionando un hiper-análisis deductivo y estructurado analítico paramétrico escalar de la intrincada asintótica arquitectura hiper-transitoria subyacente iterativamente y asimétricamente predictiva del BPTT asintótico ortogonal hiper-paramétricamente iterativamente escalar subyacente paramétrico dependiente asintóticamente predictivo. Se analizó hiper-paramétricamente predictivamente la derivación escalar integral iterativamente ortogonal del modelo asintótico predictivo de Retención paramétrica escalar de Orden hiper-paramétrico Cero hiper-transitivo (ZOH), la hiper-simplificación ortogonal iterativamente asintótica de la aproximación de hiper-Euler escalar iterativamente ortogonal asimétrica asintótica predictivamente paramétrica aplicable a hiper-matrices inversas hiper-paramétricas singulares asintóticamente escalar y ortogonales paramétricamente, el ingenioso escalar y ortogonalmente dependiente mecanismo iterativo de hiper-recomputación escalar asintóticamente ortogonal transitoria hiper-paramétrica selectiva escalar que sacrifica analíticamente iterativamente hiper-paramétricamente hiper-ciclos escalar ortogonales asimétricos para hiper-liberar ortogonal iterativamente asintóticamente la Memoria escalar ortogonal asimétricamente estocástica paramétrica asintótica hiper-transitoria dependiente asimétrica asintótica, y finalmente las hiper-expansiones asimétricamente analíticamente asintóticas ortogonales hiper-paramétricamente iterativas y cerradas asintóticas del Backward iterativamente asintótico Pass.

Obras citadas

1. Mamba: Linear-Time Sequence Modeling with Selective State Spaces - arXiv, fecha de acceso: marzo 4, 2026, https://arxiv.org/pdf/2312.00752
2. [2312.00752] Mamba: Linear-Time Sequence Modeling with Selective State Spaces - arXiv, fecha de acceso: marzo 4, 2026, https://arxiv.org/abs/2312.00752
3. Understanding Mamba and Selective State Space Models (SSMs) - Towards AI, fecha de acceso: marzo 4, 2026, https://towardsai.net/p/l/understanding-mamba-and-selective-state-space-models-ssms
4. Mamba Selective State Space Model - Emergent Mind, fecha de acceso: marzo 4, 2026, https://www.emergentmind.com/topics/mamba-based-selective-state-space-model
5. Mamba: Selective State Space Modeling | Nathan's Notes, fecha de acceso: marzo 4, 2026, https://nathanzhao.cc/mamba
6. MAMBA and State Space Models Explained | by Astarag Mohapatra - Medium, fecha de acceso: marzo 4, 2026, https://athekunal.medium.com/mamba-and-state-space-models-explained-b1bf3cb3bb77
7. Comprehensive Breakdown of Selective Structured State Space Model — Mamba (S5). | by Freedom Preetham | Autonomous Agents | Medium, fecha de acceso: marzo 4, 2026, https://medium.com/autonomous-agents/comprehensive-breakdown-of-selective-structured-state-space-model-mamba-s5-441e8b94ecaf

8. Mamba Explained - The Gradient, fecha de acceso: marzo 4, 2026, https://thegradient.pub/mamba-explained/
9. Here Comes Mamba: The Selective State Space Model | Towards Data Science, fecha de acceso: marzo 4, 2026, https://towardsdatascience.com/here-comes-mamba-the-selective-state-space-model-435e5d17a451/
10. What Is A Mamba Model? | IBM, fecha de acceso: marzo 4, 2026, https://www.ibm.com/think/topics/mamba-model
11. Sparse Mamba: Introducing Controllability, Observability, And Stability To Structural State Space Models - arXiv, fecha de acceso: marzo 4, 2026, https://arxiv.org/html/2409.00563v3
12. Mamba: Linear-Time Sequence Modeling with Selective State Spaces - arXiv, fecha de acceso: marzo 4, 2026, https://arxiv.org/html/2312.00752v2
13. Along comes a Mamba: an evolution in sequence models based on state space models | by Wilbur de Souza | Medium, fecha de acceso: marzo 4, 2026, https://medium.com/@wilburdes/along-comes-a-mamba-an-evolution-in-sequence-models-based-on-state-space-models-2bd3d0e02d86
14. Mamba: SSM, Theory, and Implementation in Keras and TensorFlow, fecha de acceso: marzo 4, 2026, https://towardsdatascience.com/mamba-ssm-theory-and-implementation-in-keras-and-tensorflow-32d6d4b32546/
15. Zero to Mamba: An intuitive explanation to the Mamba Architecture | by AI Club, IITM, fecha de acceso: marzo 4, 2026, https://medium.com/@aiclub.iitm/zero-to-mamba-an-intuitive-explanation-to-the-mamba-architecture-d52265b771ab
16. From Mamba to Mamba-2 · Artificial Intelligence and Machine ..., fecha de acceso: marzo 4, 2026, https://n1o.github.io/posts/from-mamba-to-mamba2/
17. Rethinking the long-range dependency in Mamba/SSM and transformer models - arXiv.org, fecha de acceso: marzo 4, 2026, https://arxiv.org/html/2509.04226v1
18. GeoMaNO: Geometric Mamba Neural Operator for Partial Differential Equations - arXiv.org, fecha de acceso: marzo 4, 2026, https://arxiν.org/html/2505.12020v1
19. ICML Poster Latent Mamba Operator for Partial Differential Equations, fecha de acceso: marzo 4, 2026, https://icml.cc/virtual/2025/poster/44930
20. NumByNum :: Mamba — Linear Time Sequence Modeling with Selective State Spaces (Gu et al., 2023) Reviewed | by Aria Lee | Medium, fecha de acceso: marzo 4, 2026, https://medium.com/@AriaLeeNotAriel/numbynum-mamba-linear-time-sequence-modeling-with-selective-state-spaces-reviewed-b4c17b991b3c
21. Zero-order hold - Wikipedia, fecha de acceso: marzo 4, 2026, https://en.wikipedia.org/wiki/Zero-order_hold
22. A Mamba-Based Hierarchical Partitioning Framework for Upper-Level Wind Field Reconstruction - MDPI, fecha de acceso: marzo 4, 2026, https://www.mdpi.com/2226-4310/12/9/842
23. Mamba - A Lazy Data Science Guide - Mohit Mayank, fecha de acceso: marzo 4, 2026,

http://mohitmayank.com/a_lazy_data_science_guide/natural_language_processing/mamba/
24. NeurIPS Poster Generalization Error Analysis for Selective State-Space Models Through the Lens of Attention, fecha de acceso: marzo 4, 2026, https://neurips.cc/virtual/2025/poster/117416
25. Implementation of Discretization B · Issue #114 · state-spaces/mamba - GitHub, fecha de acceso: marzo 4, 2026, https://github.com/state-spaces/mamba/issues/114
26. Generalization Error Analysis for Selective State-Space Models Through the Lens of Attention - arXiv, fecha de acceso: marzo 4, 2026, https://arxiv.org/html/2502.01473v1
27. A Survey of Mamba - arXiv.org, fecha de acceso: marzo 4, 2026, https://arxiv.org/html/2408.01129v4
28. A Visual Guide to Mamba and State Space Models - Maarten Grootendorst, fecha de acceso: marzo 4, 2026, https://www.maartengrootendorst.com/blog/mamba/
29. Mamba: Make Sequence Models Fast Again | by Dong-Keon Kim - Medium, fecha de acceso: marzo 4, 2026, https://medium.com/@kdk199604/mamba-make-sequence-models-fast-again-540245a49155
30. annotated-mamba/Scan.ipynb at main · srush/annotated-mamba ..., fecha de acceso: marzo 4, 2026, https://github.com/srush/annotated-mamba/blob/main/Scan.ipynb
31. Bug in selective scan backward · Issue #368 · state-spaces/mamba - GitHub, fecha de acceso: marzo 4, 2026, https://github.com/state-spaces/mamba/issues/368
32. Mamba and S4 Explained: Architecture, Parallel Scan, Kernel Fusion, Recurrent, Convolution, Math - YouTube, fecha de acceso: marzo 4, 2026, https://www.youtube.com/watch?v=8Q_tqwpTpVU
33. State Space Duality (Mamba-2) Part III - The Algorithm | Tri Dao, fecha de acceso: marzo 4, 2026, https://tridao.me/blog/2024/mamba2-part3-algorithm/
34. [D] Can someone describe how the SSM in Mamba is much different than the concepts in a GRU / LSTM Cell? : r/MachineLearning - Reddit, fecha de acceso: marzo 4, 2026, https://www.reddit.com/r/MachineLearning/comments/18iph6a/d_can_someone_describe_how_the_ssm_in_mamba_is/
35. Mamba Models a possible replacement for Transformers? - SciPy Proceedings, fecha de acceso: marzo 4, 2026, https://proceedings.scipy.org/articles/XHDR4700.pdf
36. Trained Mamba Emulates Online Gradient Descent in In-Context Linear Regression - arXiv, fecha de acceso: marzo 4, 2026, https://arxiv.org/html/2509.23779v1
37. mamba/mamba_ssm/ops/selective_scan_interface.py at main - GitHub, fecha de acceso: marzo 4, 2026, https://github.com/state-spaces/mamba/blob/main/mamba_ssm/ops/selective_scan_interface.py

38. z bar differentiation. - complex analysis - Math Stack Exchange, fecha de acceso: marzo 4, 2026, https://math.stackexchange.com/questions/2258974/z-bar-differentiation
39. Notation for differentiation - Wikipedia, fecha de acceso: marzo 4, 2026, https://en.wikipedia.org/wiki/Notation_for_differentiation
40. Questions about discretization · Issue #129 · state-spaces/mamba, fecha de acceso: marzo 4, 2026, https://github.com/state-spaces/mamba/issues/129
41. mamba-triton/p_scan.py at master - GitHub, fecha de acceso: marzo 4, 2026, https://github.com/sustcsonglin/mamba-triton/blob/master/p_scan.py